PROYECTO DE

APRENDIZAJE SUPERVISADO Y NO SUPERVISADO

SPOTIFY TRACK



Integrantes:
Benjamín Neira
Gustavo Alvial
Matías Turra

Conocimiento y contexto de negocio

Spotify



Auge de plataformas de streaming.

Predicción de popularidad.

Segmentación.

Set de datos

114.000 registros

21 columnas.

89.740 canciones.

KPIs

Tasa de detección temprana de éxitos (50% al contar el siguiente mes)

50%

MAE < 8 puntos de popularidad.

< 8

Métricas de clasificación > 0.6

> 0.6

Integridad y ética de los datos

Auditoría de los datos

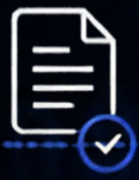




Conexión con repositorio GitHub.







Hash criptográfico para la veracidad del dataset.

Aspectos éticos

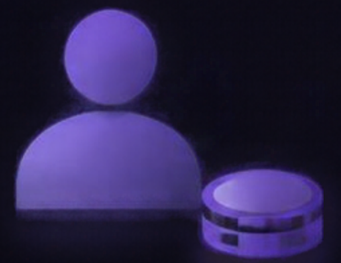
Sellos discográficos





Sesgo de la variable popularidad

Artistas independientes



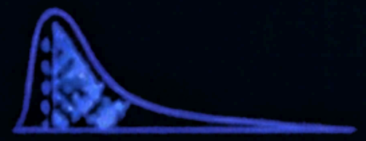
Hallazgos del EDA y creación de variables

Duplicidad masiva

23.366
canciones duplicadas debido al género

894
duplicados reales

Problemáticas principales



Distribución de la variable popularity



Duplicidad por género



Atípicos en variables de [0, 1]

Creación de variables

artista_principal

79% correlación

0% 50% 100%

es_colaboracion

10% correlación

0% 50% 100%

Pipeline de transformación de variables

1 Variables categóricas → Target Encoding

artista_principal
correlación de 0.79

-1 0 0.79 1

</> Se codificará con Target Encoding

track_genre
correlación de 0.57

-1 0 0.57 1

</> Se codificará con Target Encoding

2 Variable binaria → Passthrough

01
10

es_colaboración
correlación 0.10

Se dejará con **passthrough** por ser binaria

3 Variables contínuas → Winsorizer + StandardScaler

Variables contínuas con correlación +3%



Modelos de regresión: popularity

MEJOR DESEMPEÑO

LinearRegression

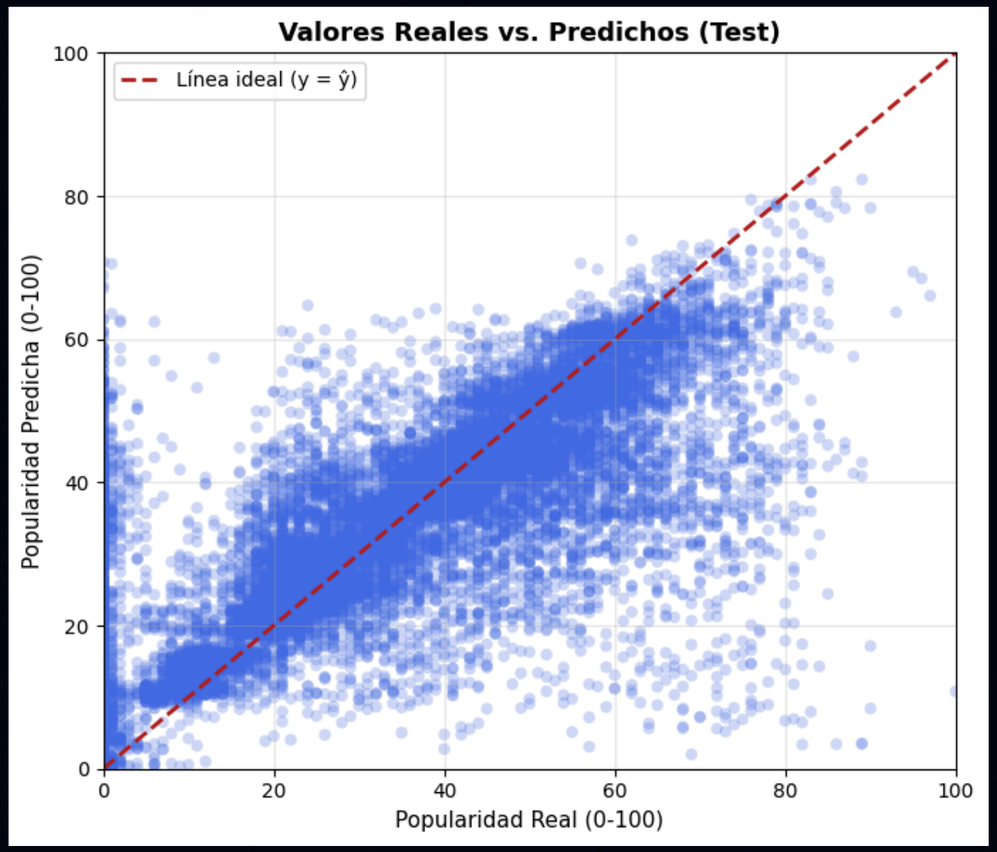
R^2:	MAE:	Score entrenamiento:	Score test:
0.73	9.2	0.67	0.54

RandomForest

R^2:	MAE:	Score entrenamiento:	Score test:
0.75	8.6	0.69	0.56

DecisionTree

R^2:	MAE:	Score entrenamiento:	Score test:
0.41	11.6	0.44	0.17



Modelos de clasificación: popularity

Regresión Logística

Accuracy:	F1 Score:	ROC AUC Score:	Precision:	Recall:
0.6922	0.6906	0.9136	0.6899	0.6922

Decision Tree con RandomSearchCV

Accuracy:	F1 Score:	ROC AUC Score:	Precision:	Recall:
0.6951	0.6937	0.9126	0.6943	0.6951

Mejor desempeño

Regresión Logística con RandomSearchCV

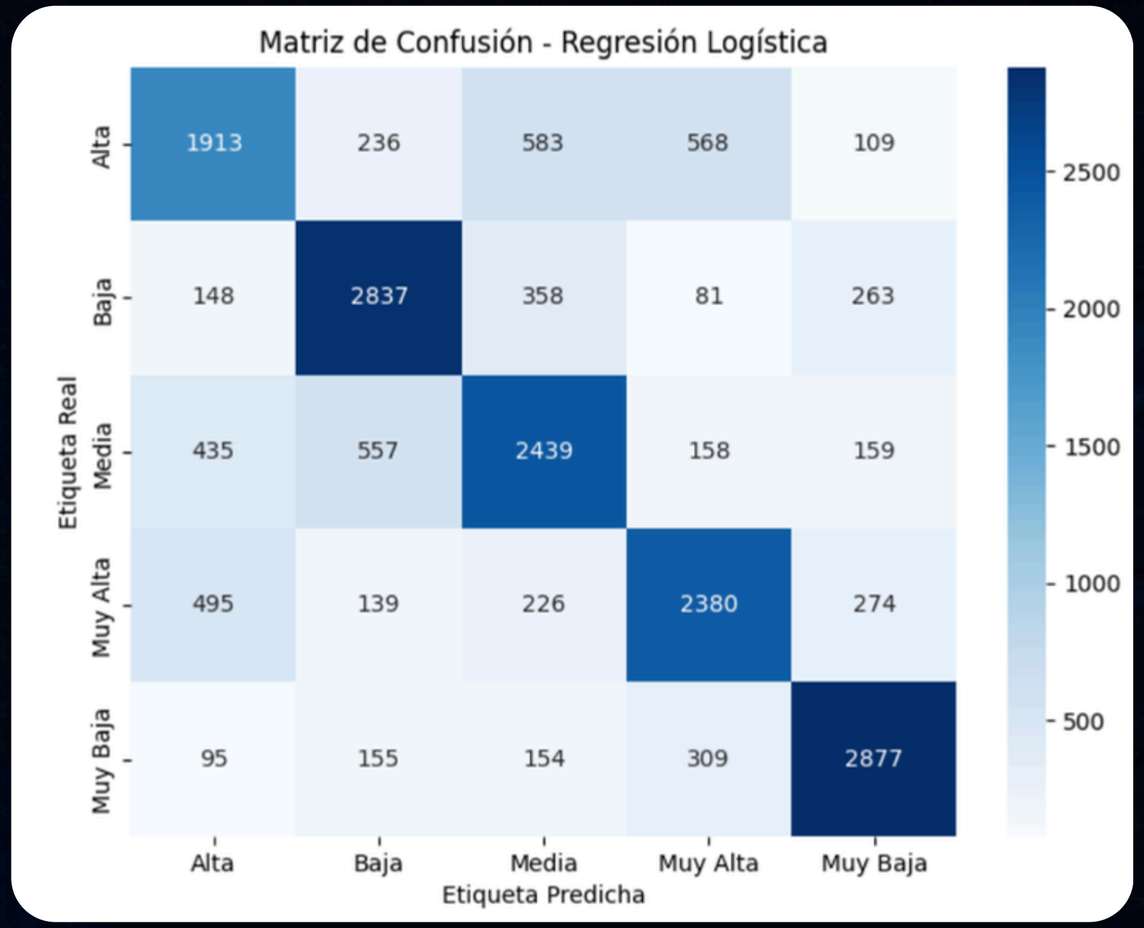
Accuracy:	F1 Score:	ROC AUC Score:	Precision:	Recall:
0.6934	0.6919	0.9136	0.6913	0.6934

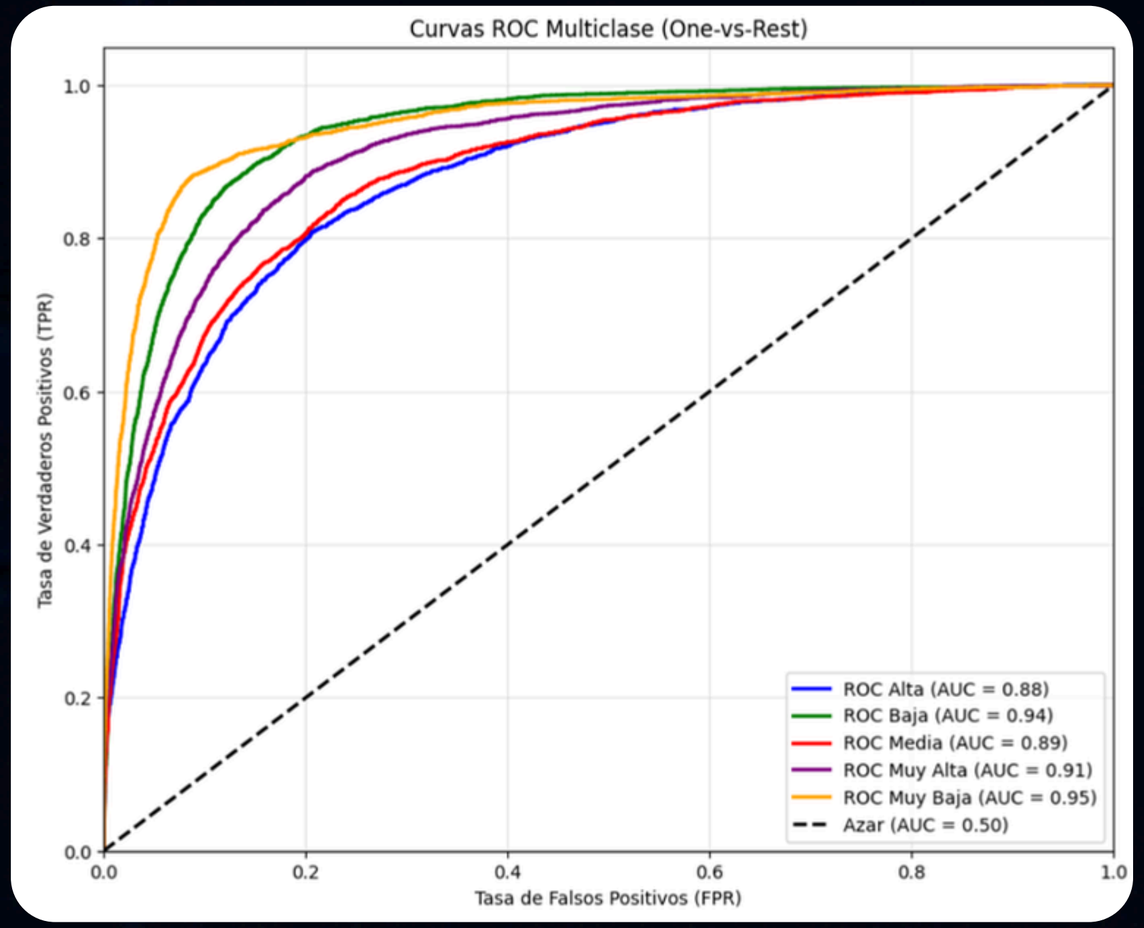
Decision Tree

Accuracy:	F1 Score:	ROC AUC Score:	Precision:	Recall:
0.6092	0.6092	0.7566	0.6093	0.6092

- Score del modelo en entrenamiento: 0.76621
- Score del modelo en test: 0.69345

Modelos de clasificación: popularity





APRENDIZAJE
NO SUPERVISADO

Objetivo: Determinar perfiles musicales para mejorar recomendaciones.

Variables utilizadas: Numéricas asociadas al perfil sonoro.

Utilización de RobustScaler
Utilización de mediana para las imputaciones



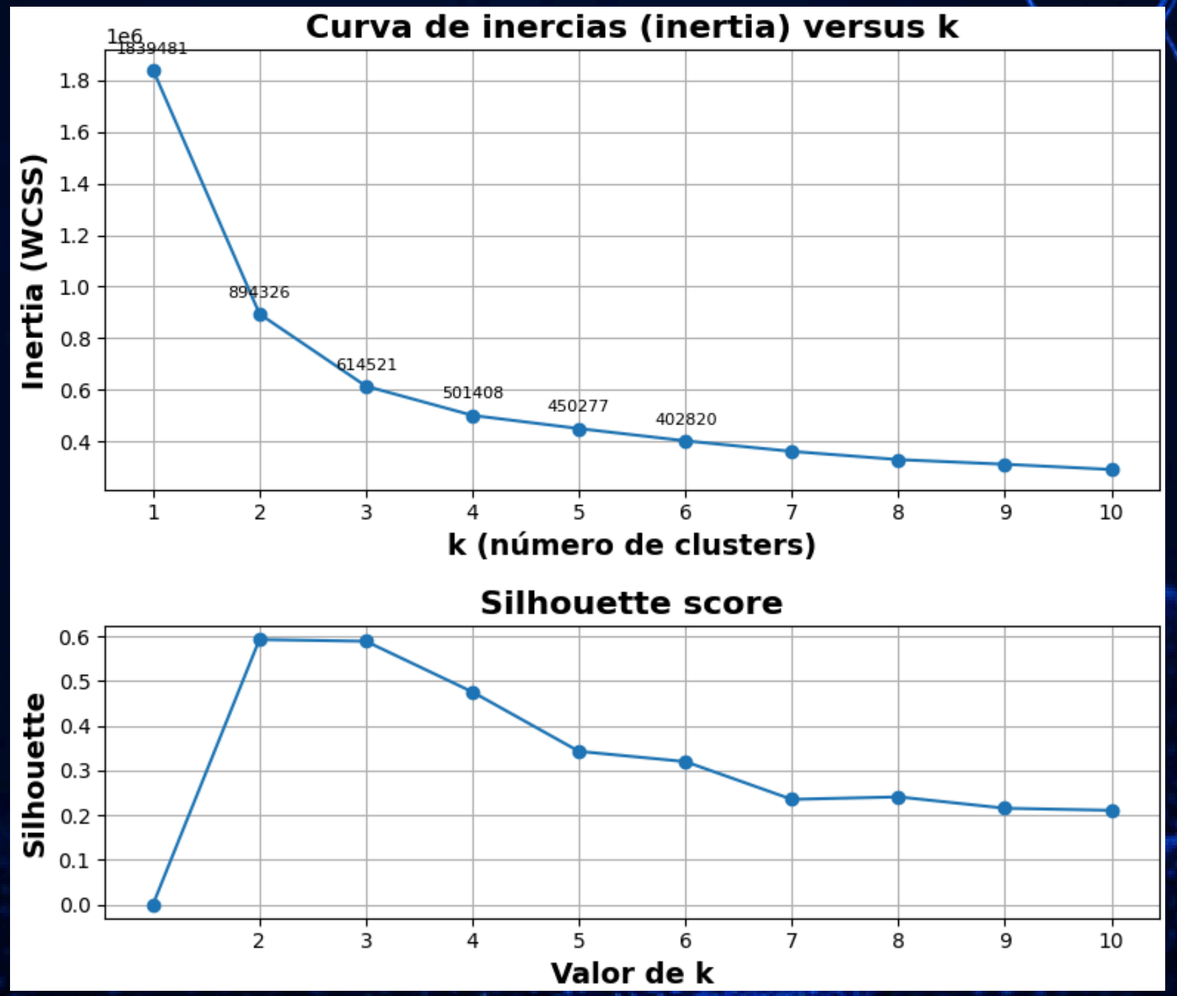
Modelo de segmentación: K-Means

Número de clusters (k):

3

Silhouette score:

0.59



Visualización con PCA

Varianza componente 1

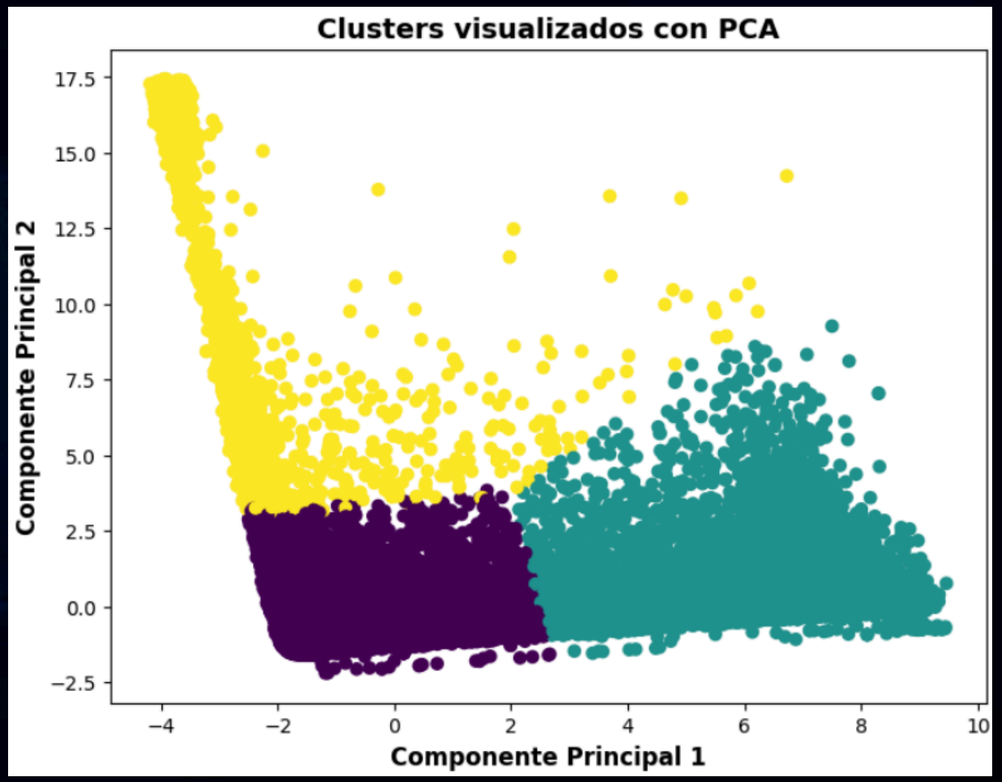
0.56

Varianza componente 2

0.25

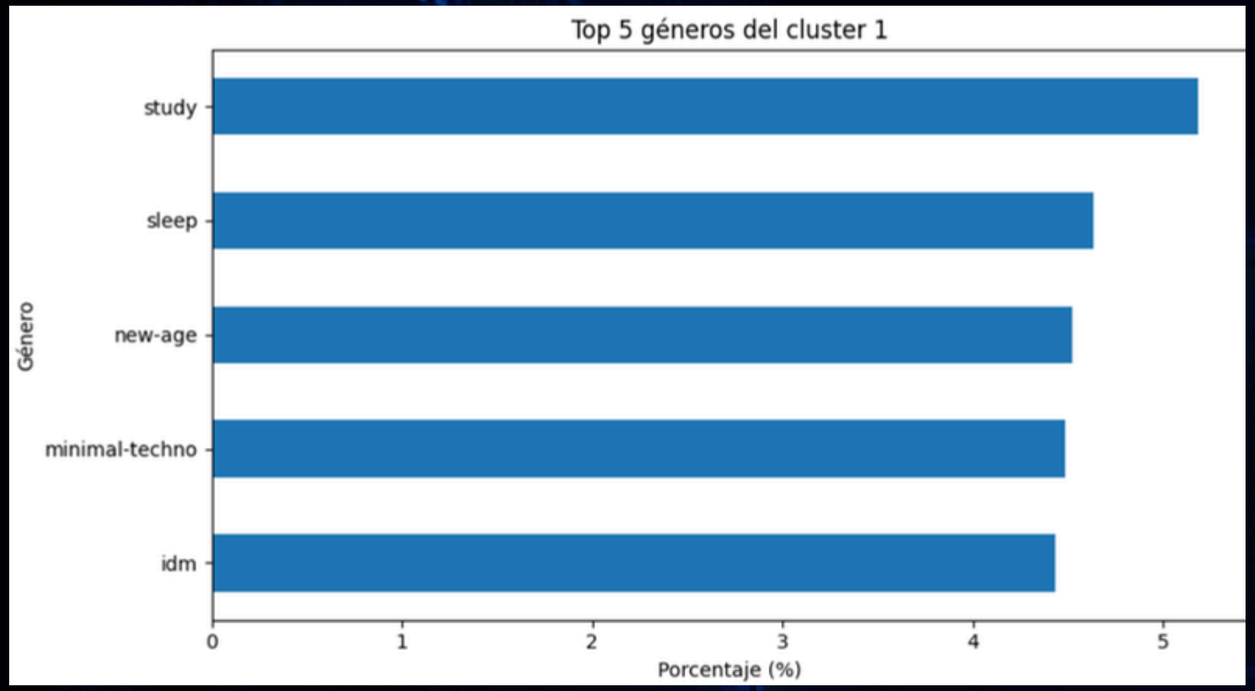
Varianza acumulada

0.81

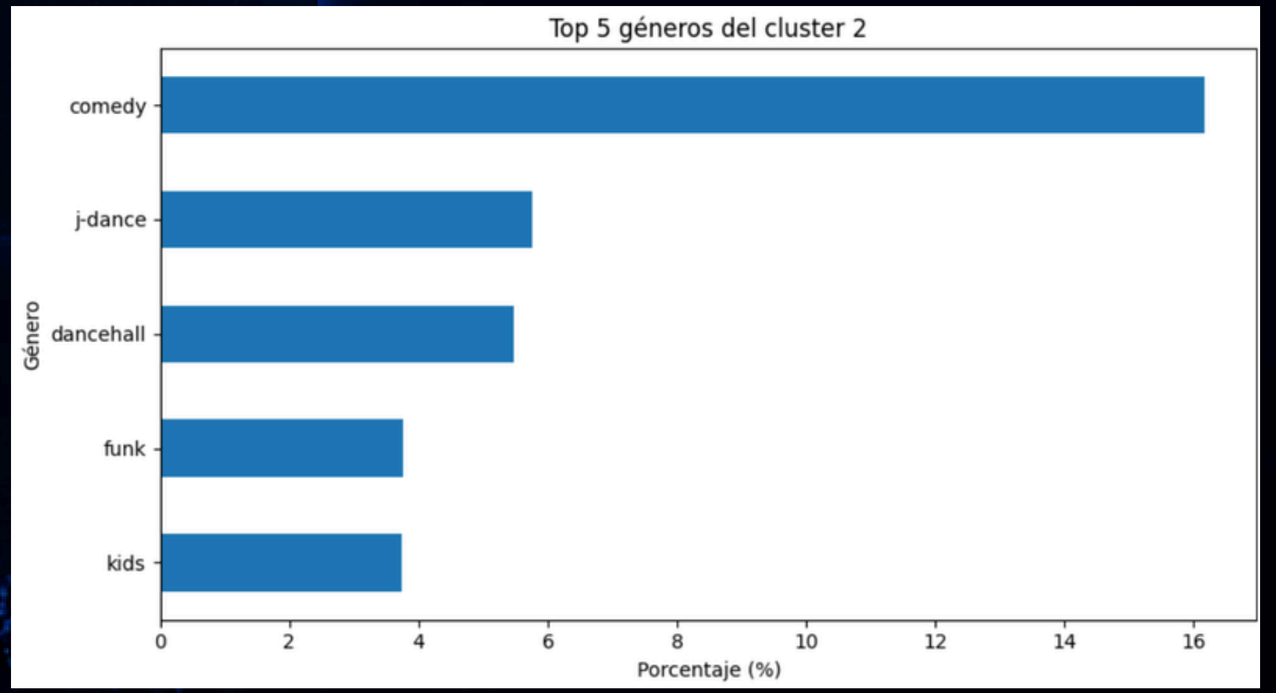


Caracterización de Clusters

Hallazgos clave y recomendaciones estratégicas



cluster	n_canciones	popularity_mediana
0	67030	36.0
1	17460	24.0
2	5250	27.0



Caracterización de Clusters

Hallazgos clave y recomendaciones estratégicas

Cluster 0

(El núcleo de la plataforma)

Concentra aproximadamente el **75%** del total de canciones.

Presenta la mayor variedad de géneros **(113 géneros únicos)** y los niveles más altos de popularidad, consolidándose como la columna vertebral del catálogo.

Puerta de entrada para nuevos usuarios.
Lanzamientos masivos, promociones de artistas consolidados y campañas publicitarias generales.

Cluster 1

(Nicho de relajación y escucha activa)

Muestra una marcada especialización con la menor diversificación

Sus canciones están fuertemente orientadas a contextos de bienestar, calma y concentración.

Diseñar y promocionar playlists temáticas basadas en momentos del día o actividades.

Cluster 2

(Nicho de alta energía)

Es el segmento más exclusivo o minoritario del dataset **(6%** del total)

enfocado principalmente en ritmos de baile, optimismo y notas alegres.

Crear playlists para entrenamiento, fiestas o fin de semana puede generar altos niveles de retención.

Conclusiones

Limpieza estructural

Sinergia acústica

Optimización algorítmica

